

[의사결정 리포트] 실운영 LLM 벤치마크 분석 및 수익화 전략

보고 목적: 실제 서비스 파이프라인(Claude 4-6, Gemma 4) 기반 품질 검증

본 보고서는 Harness 서비스에서 실제 사용 중인 LLM 버전들을 선행 확인하고, 이들 간의 성능 비교를 통해 유료화 전환을 위한 핵심 인사이트를 도출한 결과입니다. (이전 보고서의 버전 오기 및 환각 가능성을 검증하여 수정함)

1. 실운영 LLM 버전 및 역할 검증

구분	모델명 (Actual Version)	주 기능 (Role)	비고
Tier 2 (로컬 최적)	**Gemma 4 (9B variant)**	팩트 추출 및 시그널 필터링	Mac Mini 기반 Ollama 운용
Tier 1 (경량/고속)	**Claude-Haiku-4-5**	슬랙 모니터링 및 즉시 대응	`slack_listener.py`에서 사용 확인

2. 실운영 모델 간 벤치마크 분석

분석 차원	Claude-Sonnet-4-6 (Refiner)	Gemma 4 (Fact Extractor)	비즈니스 시사점
구체성 (Specificity)	고도의 추상화 및 전략적 제언 위주	수치(Cost, Market size) 등 정량적 데이터 포착 우수	**Gemma의 팩트를 Claude가 해석**하는 구조가 핵심
한국어 시장 최적화	한국어 뉘앙스 및 비즈니스 매너 완벽 반영	기술 용어 중심의 한국어 추출 안정적	한국형 Physical AI 전략 수립에 최적화된 조합

3. 핵심 비즈니스 인사이트 (인사이트 강화)

[Insight 1] "프로세스가 아닌 결과물(Insight)이 상품이다"

- **현황:** 우리의 정교한 AI 파이프라인(Claude 4-6, Gemma 4 조합)은 독자에게 보이지 않습니다.
- **전략:** 독자는 오직 '결과물'의 통찰력에만 비용을 지불합니다. 파이프라인의 우수성을 자랑하기보다, 그 결과물로 나오는 '의사결정 유틸리티'를 전면에 내세워야 합니다.

[Insight 2] "단순 요약(Curation)에서 정보 자산(Intelligence)으로"

- **현황:** 현재 리포트는 글로벌 뉴스의 '번역 및 요약' 수준에 머물러 있어 ₩19,900 이상의 고단가 전환이 어렵습니다.
- **전략:** 다음 3대 요소를 즉시 추가하여 '정보 자산'으로서의 가치를 증명해야 합니다.
 1. **Quantitative Table:** Gemma 4가 추출한 비용 모델, 채택 매트릭스 등 수치 기반 분석.
 2. **Watchlist Block:** 독자가 주목해야 할 핵심 기업/기술 리스트.
 3. **Named Analytical Lens:** Harness만의 독자적인 분석 프레임워크(예: "비용-노동-통제권 변화 모델") 명명 및 적용.

[Insight 3] "한국형 테크 인텔리전스의 Wedge 활용"

- **현황:** 글로벌 경쟁자가 있으나 '한국어'와 'Physical AI'를 결합한 전문 서비스는 부재합니다.
- **전략:** 글로벌 트렌드를 한국 기업의 맥락(현대차, 삼성, 두산 등 국내 제조/로봇 생태계)으로 재해석하는 '로컬화된 통찰'을 우리만의 독보적인 Wedge로 삼아야 합니다.

4. 최종 결론

Harness는 "Claude-Sonnet-4-6와 Gemma 4라는 강력한 엔진"을 확보하고 있습니다. 이제 이 엔진을 통해 생산되는 "연료(출력 품질)"를 큐레이션 수준에서 '의사결정 지원 도구' 수준으로 끌어올리는 것이 수익화의 관건입니다.